

Analisis Krisis Metabolik pada Sepsis: Pengembangan Sistem Peringatan Dini Hipoksia Jaringan Berbasis Multi-Layer Perceptron dan Explainable AI (SHAP)

Nathaniel Jonathan Rusli - 13523013¹

Maheswara Bayu Kandra - 13523015²

Peter Wongsoredjo - 13523039³

Program Studi Teknik Informatika
Sekolah Teknik Elektro dan Informatika

Institut Teknologi Bandung, Jl. Ganesha 10 Bandung 40132, Indonesia

13523013@std.stei.itb.ac.id, 13523015@std.stei.itb.ac.id, 13523039@std.stei.itb.ac.id

I. PENDAHULUAN

1.1 Latar Belakang

Krisis metabolik pada sepsis merupakan salah satu penyebab utama tingginya kematian di Unit Perawatan Intensif (ICU) [12]. Sepsis memicu gangguan mikrosirkulasi yang menghambat pasokan oksigen ke jaringan sehingga mengakibatkan kondisi hipoksia jaringan [2]. Ketiadaan oksigen tersebut secara langsung menghentikan proses respirasi aerobik di dalam mitokondria untuk menghasilkan adenosine triphosphate (ATP) [1]. Sebagai mekanisme kompensasi untuk bertahan hidup, sel terpaksa beralih ke jalur glikolisis anaerobik yang berujung pada akumulasi asam laktat secara drastis (asidosis laktat), yang ditandai melalui penurunan nilai pH darah serta parameter *base excess* [7]. Kondisi ini memiliki progresivitas yang sangat cepat yang menyebabkan kegagalan multiorgan [12]. Oleh karena itu, sistem peringatan dini yang mampu mendeteksi risiko hipoksia jaringan secara cepat sangat krusial untuk memandu intervensi klinis [3].


Kendala utama dalam penelitian ini adalah karakteristik data ICU yang heterogen, di mana penanda respirasi seluler langsung seperti kadar laktat memiliki tingkat *sparsity* yang sangat tinggi akibat pengambilan sampel laboratorium yang intermiten [5]. Sementara itu, parameter tanda vital yang sifatnya kontinu memiliki pola fluktuasi non-linear yang terlalu kompleks untuk dianalisis manual secara cepat oleh tenaga medis [3].

Untuk menjembatani kesenjangan tersebut, pendekatan komputasi Multi-Layer Perceptron (MLP) diterapkan karena kapabilitasnya dalam mengekstrak fitur abstrak dan mengenali sinyal risiko dari kombinasi data yang tidak lengkap [11]. Untuk mengatasi sifat model yang *black-box*, metode Explainable AI (XAI) berbasis Shapley Additive exPlanations (SHAP) diintegrasikan untuk membongkar kontribusi matematis model, sekaligus membuktikan bagaimana fitur-fitur saling berinteraksi menggantikan sinyal parameter metabolik utama yang hilang [8].

1.2 Dasar Teori

1.2.1 Patofisiologi Sepsis dan Krisis Seluler

Sepsis merupakan kelainan yang menyebabkan inflamasi yang merusak endotel dan sirkulasi darah [12]. Gangguan ini menghambat hantaran oksigen ke jaringan sehingga terjadi hipoksia jaringan [2]. Di tingkat seluler ketiadaan oksigen menghentikan rantai pasokan elektron di membran dalam mitokondria. Tanpa oksigen, proses fosforilasi oksidatif dan siklus Krebs berhenti, yang mengakibatkan kegagalan produksi *adenosine triphosphate* (ATP) melalui respirasi aerobik [1].




Gambar. 1. Pengaruh Sepsis pada Gangguan Respirasi Aerobik

Untuk mempertahankan ketersediaan energi, sel beralih ke jalur glikolisis anaerobik di sitoplasma [10]. Jalur ini tidak efisien karena hanya menghasilkan 2 ATP per molekul glukosa, jauh lebih rendah dibanding respirasi aerobik yang menghasilkan sekitar 36 ATP [10]. Dampak utama dari peningkatan glikolisis anaerobik ini adalah produksi asam laktat secara berlebihan [7]. Akumulasi asam laktat yang terdisosiasi menjadi laktat dan ion hidrogen memicu asidosis laktat dan berujung pada kegagalan multiorgan [7, 12].

1.2.2 Multi-Layer Perceptron

Multi-Layer Perceptron (MLP) merupakan jenis *artificial neural network* yang terdiri atas satu *layer input*, satu atau lebih *hidden layer*, dan satu lapisan *output* [11]. Pada pemodelan ini, lapisan *input* menerima fitur klinis pasien yang telah melalui proses standarisasi. Setiap neuron pada lapisan bersifat *fully connected* dengan neuron pada lapisan berikutnya melalui bobot dan bias tertentu [4].



Gambar. 2. Ilustrasi Multi-Layer Perceptron (MLP)

Perhitungan pada *hidden layer* memanfaatkan fungsi aktivasi Rectified Linear Unit (ReLU) [9], yang didefinisikan sebagai:

$$f(x) = \max(0, x) \quad (1)$$

untuk mengatasi *vanishing gradient* dan mempercepat konvergensi model. Untuk menghasilkan prediksi biner berupa probabilitas risiko, lapisan *output* menggunakan fungsi aktivasi Sigmoid [4]:

$$f(x) = \frac{1}{1+e^{-x}} \quad (2)$$

Model dioptimalkan dengan Binary Cross-Entropy (BCE) *loss function* untuk mengukur selisih antara probabilitas prediksi dengan label asli pasien. Pembaruan bobot jaringan dilakukan secara iteratif menggunakan optimasi *Adaptive Moment Estimation* (Adam) untuk memastikan efisiensi pemrosesan data non-linear [6].

1.2.3 Representasi Kontribusi Fitur dengan SHAP

Shapley Additive exPlanations (SHAP) merupakan metode berbasis *game theory* yang digunakan untuk menjelaskan *output* dari model *black-box* seperti *artificial neural network* [8]. SHAP mengukur kontribusi dari setiap fitur terhadap deviasi hasil prediksi model dari nilai rata-rata (*baseline*). Nilai SHAP (ϕ_i) mengatribusikan bobot pengaruh fitur ke arah prediksi positif atau negatif melalui persamaan berikut.

$$\phi_i = \sum_{S \subseteq F \setminus \{i\}} \frac{|S|!(|F|-|S|-1)!}{|F|!} [f_x(S \cup \{i\}) - f_x(S)] \quad (3)$$

di mana F melambangkan total seluruh fitur klinis, S merupakan himpunan bagian dari fitur yang tidak mencakup fitur ke- i , dan $f_x(S)$ merupakan fungsi estimasi prediksi model untuk kombinasi fitur tertentu [8].

1.3 Rumusan Masalah

Berdasarkan latar belakang dan permasalahan yang telah diuraikan, rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana arsitektur Multi-Layer Perceptron dapat dioptimalkan untuk memprediksi risiko krisis metabolik akibat hipoksia jaringan pada pasien sepsis dengan data ber-*sparsity* tinggi?
2. Bagaimana SHAP dapat membongkar sifat *black-box* model MLP serta menjelaskan interaksi fitur fisiologis pendukung dalam menggantikan sinyal parameter metabolik utama yang hilang?

1.4 Tujuan Penelitian

Tujuan yang ingin dicapai dalam penelitian ini adalah sebagai berikut.


1. Mengembangkan dan mengoptimalkan model klasifikasi biner berbasis *Multi-Layer Perceptron* (MLP) untuk mendeteksi risiko krisis metabolik secara dini pada pasien sepsis.
2. Menerapkan metode SHAP untuk memetakan nilai kontribusi dan interaksi parameter fisiologis pendukung dalam menghasilkan prediksi yang valid ketika indikator metabolik utama mengalami kekosongan data.

II. METODE

2.1 Alur Penelitian

Penelitian ini menerapkan alur pemrosesan *end-to-end* yang terbagi menjadi enam fase utama untuk membangun sistem peringatan dini krisis metabolik. Proses diawali dengan eksplorasi data mentah (EDA) guna memetakan karakteristik rekam medis ICU, lalu dilanjutkan dengan tahap pemfilteran dan *feature engineering* yang mencakup seleksi kohort, imputasi temporal, serta ekstraksi penanda hipoksia. Selanjutnya, dilakukan pembagian dan normalisasi data secara terisolasi pada level pasien guna mencegah *data leakage*.

Data klinis tersebut kemudian digunakan pada tahap pelatihan model MLP dan *temporal smoothing* untuk mengenali pola non-linear sepsis sekaligus mereduksi *noise* prediksi jangka pendek. Terakhir, sistem diukur melalui Evaluasi Kinerja Model pada metrik per jam dan per pasien, serta ditutup dengan analisis *explainability* menggunakan SHAP secara *post-hoc* untuk memastikan keluaran model dapat dipertanggungjawabkan secara medis.



Gambar. 3. Flowchart Alur Penelitian

2.2 Pengumpulan dan Karakteristik Dataset

Penelitian ini menggunakan dataset *time-series* klinis longitudinal beresolusi per jam dari PhysioNet/Computing in Cardiology Challenge 2019 yang diakses melalui repositori Kaggle. Data ini bersumber dari unit perawatan intensif (ICU) di dua sistem rumah sakit Amerika Serikat, dengan target prediksi berupa variabel biner SepsisLabel berdasarkan kriteria klinis Sepsis-3. Karakteristik metrik dan ringkasan statistik dari dataset mentah ini disajikan pada Tabel I.

Dataset ini menghadirkan tantangan berupa ketidakseimbangan kelas dan *sparsity* yang sangat tinggi pada fitur laboratorium (97,33% *missing values* untuk fitur Lactate dan 93,07% untuk fitur pH). Perbedaan *sparsity* yang kontras antara parameter laboratorium dan tanda vital merefleksikan praktik klinis riil di ICU yang mana pengujian laboratorium dilakukan secara selektif berdasarkan indikasi medis dan urgensi krisis metabolik pasien, sedangkan tanda vital dipantau secara kontinu dan otomatis oleh perangkat bedside.

TABEL I

KARAKTERISTIK DATASET CARDIOLOGY CHALLENGE 2019

Parameter	Statistik
Total Pasien Unik	40.336
Total Baris <i>Time-series</i>	1.552.210
Total Fitur	43
Rasio Kelas (Positif:Negatif)	1:54,6

2.3 Data Preprocessing

Tahap ini dirancang untuk mengatasi tantangan *sparsity* yang tinggi, ketidakseimbangan kelas yang ekstrem, serta potensi *data leakage* melalui enam langkah berurutan:

1. Pembatasan Kohort: Analisis difokuskan pada pasien dengan minimal satu pengukuran laktat yang valid, mengurangi dataset menjadi 12.493 pasien (566.035 baris) untuk menyaring populasi ICU yang secara spesifik memerlukan pemantauan metabolik intensif.
2. Rekayasa Fitur Klinis dan Indikator Pengukuran: Menggabungkan ekstraksi pola medis dan informative missingness. Pertama, 7 indikator biner ditambahkan (berakhiran *_Measured*) karena keputusan pengujian oleh tenaga medis merupakan sinyal prediktif. Kedua, 7 parameter turunan dikonstruksi berdasarkan kriteria Sepsis-3 sebelum dilakukannya imputasi data: trajektori metabolik (Lactate_max6h, Lactate_delta6h, dan Lactate_abnormal), indikator desaturasi hipoksia (O2Sat_min6h dan O2Sat_low), serta rasio keparahan kritis berupa SF Ratio (SpO_2/FiO_2) untuk proksi komplikasi ARDS dan Shock Index (HR/SBP) untuk deteksi awal syok hemodinamik.
3. Imputasi Temporal & Fisiologis: Kekosongan data diatasi dengan *forward-fill* per pasien berbatas waktu (maksimal 12 jam untuk parameter laboratorium dan 24 jam untuk tanda vital) guna mencegah propagasi nilai yang usang. Sisa nilai kosong di awal observasi diimputasi dengan nilai fisiologis normal (misalnya Laktat 1,0 mmol/L, O2Sat 98,0%, pH 7,4, BaseExcess 0,0).
4. Penyeimbangan Level Pasien: *Downsampling* kelas mayoritas (negatif) dilakukan pada level pasien dengan rasio 1:2 (positif:negatif) menggunakan *seed* 42. Pendekatan ini tetap menjaga integritas *time-series* dan mencegah kontaminasi informasi antar-jam, menyisakan 5.457 pasien unik.
5. Seleksi Fitur: Menghapus 8 fitur administratif dan demografis statis (seperti Age, Gender, Unit1) karena tidak relevan untuk peringatan dini dinamis.
6. Pemisahan Data dan Normalisasi: Dataset dibagi secara *stratified* (80:20) pada level pasien untuk mencegah *data leakage*, menghasilkan 4.365 pasien *training* dan 1.092 pasien *testing*. Ketidakseimbangan baris khusus pada set *training* diatasi dengan *row-level oversampling*. Terakhir, seluruh fitur distandarisasi dengan StandardScaler.

2.4 Arsitektur MLP dan Temporal Smoothing

Klasifikasi biner krisis metabolik diimplementasikan menggunakan arsitektur Multi-Layer Perceptron (MLP) *feedforward* dengan kompresi dimensi bertahap untuk mempelajari representasi hierarkis penanda klinis tanpa risiko *overfitting*. Pelatihan model menggunakan skema pembagian 10% data secara internal sebagai himpunan validasi untuk menguji konvergensi melalui mekanisme *early stopping* (patience = 10). Detail struktural arsitektur

dan hyperparameter pelatihan MLP dirangkum dalam Tabel II.

Pasca-inferensi pada set pengujian, probabilitas prediksi mentah diproses menggunakan metode *temporal smoothing* berbasis *rolling mean* dengan *sliding window* selama 6 jam per pasien. Secara klinis, pendekatan ini selaras dengan patofisiologi progresi sepsis yang umumnya berkembang dalam rentang 6–12 jam yang krusial untuk mereduksi *noise* akibat fluktuasi *probabilitas* jangka pendek antara jam yang berdekatan tanpa mendistorsi arah tren klinis pasien.

TABEL II
ARSITEKTUR DAN HYPERPARAMETER MLP

Komponen	Spesifikasi
Dimensi <i>Input</i>	48 fitur
Arsitektur <i>Hidden Layer</i>	64 → 32 → 16 neuron
Fungsi Aktivasi	ReLU
Dimensi <i>Output</i>	2 neuron (biner)
Algoritma Optimasi	Adam optimizer
Regularisasi	L2 <i>Weight Decay</i> (1e-4)
Ukuran <i>Batch</i>	256
Iterasi Maksimum	200 iterasi

2.5 Strategi Evaluasi Kinerja Model

Evaluasi kinerja model dilakukan pada dua tingkat komplementer menggunakan probabilitas prediksi hasil penghalusan temporal, yaitu tingkat per-jam dan tingkat per-pasien. Evaluasi per jam bertindak sebagai metrik operasional utama sistem peringatan dini melalui penyesuaian ambang batas secara adaptif untuk mencapai target *recall* minimal 0,75. Pendekatan ini memprioritaskan sensitivitas tinggi demi meminimalkan risiko keterlambatan deteksi yang mengancam jiwa pasien ICU dengan melaporkan metrik *recall*, spesifisitas, presisi, dan ROC-AUC. Sementara itu, evaluasi per pasien menguji validitas instrumen stratifikasi risiko klinis melalui agregasi rata-rata dari tiga probabilitas tertinggi pasien yang dinilai lebih tangguh terhadap lonjakan data tunggal sesaat. Label pasien ditetapkan berdasarkan nilai maksimum indikator sepsis selama seluruh durasi perawatan di ICU dengan target penyesuaian *recall* yang selaras, di mana performa akumulatif pada tingkat pasien ini dilaporkan secara spesifik melalui visualisasi struktur matriks kebingungan.


2.6 Implementasi Explainable AI (SHAP)

Untuk memvalidasi transparansi model MLP dan memastikannya mengandalkan penanda biologis yang relevan, metode SHAP diterapkan melalui *post-hoc*

analysis. Mengingat MLP bukan model berbasis pohon, pendekatan model-agnostic KernelExplainer digunakan untuk mengestimasi atribusi fitur. Konfigurasi komputasi menggunakan 50 sampel training sebagai data latar belakang (*baseline*) dan 500 observasi evaluasi dari set *testing*. Pengambilan sampel evaluasi ini dilakukan secara *stratified* (250 positif, 250 negatif) dengan batas 100 permutasi per observasi guna mencegah tenggelamnya sinyal parameter krusial akibat dominasi kelas mayoritas. Matriks nilai SHAP kemudian diekstraksi secara spesifik untuk kelas positif (SepsisLabel = 1) dan divisualisasikan melalui *beeswarm summary plot* untuk memetakan arah pengaruh magnitudo fitur terhadap prediksi risiko, serta diurutkan berdasarkan rata-rata nilai absolut SHAP untuk mengidentifikasi tingkat kepentingan fitur secara global.


III. HASIL DAN DISKUSI

3.1 Analisis Kinerja Multi-Layer Perceptron




Gambar. 4. Kurva penurunan *loss* dan akurasi validasi model MLP.

Arsitektur Multi-Layer Perceptron yang dibangun terbukti menghasilkan *loss curve* yang menurun secara monoton hingga mencapai titik jenuh yang stabil, berjalan selaras dengan grafik akurasi validasi yang mendatar pada performa tertingginya. Fenomena tersebut mengindikasikan bahwa model telah mencapai kondisi konvergensi yang optimal (*good fit*). Struktur tiga lapisan tersembunyi ini memberikan kapasitas yang mumpuni bagi *neural network* untuk memetakan interaksi non-linear yang kompleks di antara berbagai penanda klinis heterogen di ICU.



Gambar. 5. *Confusion matrix* pada data uji


Evaluasi kuantitatif model dilakukan pada 20% data uji independen yang terdiri dari 55.891 baris dari 1.092 pasien. Pemrosesan awal menggunakan transformasi *rolling mean* dengan jendela waktu enam jam diterapkan untuk melakukan penghalusan temporal pada tingkat pasien guna menstabilkan estimasi probabilitas prediksi biner. Pada evaluasi tingkat per-jam yang merepresentasikan metrik operasional langsung dari sistem peringatan dini, model berhasil memperoleh nilai *recall* sebesar 0,750 dan tingkat *specificity* sebesar 0,349. Dalam konteks klinis ICU, preferensi komputasi ini sangat rasional. Model lebih mengutamakan keselamatan jiwa dengan meminimalkan risiko adanya kasus sepsis yang luput dari deteksi (*false negatives*), meskipun keputusan tersebut membawa konsekuensi operasional berupa tingginya laju alarm palsu (*false alarms*) yang diakibatkan oleh rendahnya nilai spesifisitas di lapangan.



Gambar. 6. ROC Curve Model MLP

Melalui pengujian performa pada tingkat per-jam, grafik Receiver Operating Characteristic (ROC) menghasilkan nilai Area Under the Curve (AUC) sebesar 0,592. Karakteristik performa ini menunjukkan bahwa sistem lebih mengutamakan sensitivitas atau kemampuan penemuan dini kasus krisis metabolik dibandingkan dengan menekan laju alarm palsu, konsisten dengan pertimbangan klinis di ICU, di mana keterlambatan penanganan sepsis memiliki progresivitas cepat yang berujung pada kegagalan kematian sehingga biaya klinis akibat keterlambatan diagnosis jauh lebih destruktif daripada beban operasional akibat alarm palsu.


Confusion Matrix (Patient-Level) — 1,092 pasien | thr=0.468



Gambar. 7. Confusion matrix performa pada tingkat per-pasien.

Ketika evaluasi dialihkan dari basis per-jam menuju analisis akumulatif tingkat per-pasien menggunakan metode agregasi rata-rata dari tiga nilai probabilitas tertinggi, kinerja model mengalami peningkatan yang signifikan. Hasil *specificity* pada tingkat pasien ini melonjak naik mencapai angka 0,423 dengan mempertahankan tingkat *recall* konstan pada angka 0,750. Distribusi ini menunjukkan berkurangnya akumulasi alarm palsu secara drastis saat jendela pengamatan diperluas mengikuti keseluruhan durasi perawatan seorang pasien.

3.2 Analisis Kualitatif dan Interpretabilitas SHAP



Gambar. 8. Grafik distribusi SHAP kontribusi fitur

Penerapan metode Explainable AI melalui SHAP berhasil membongkar model Multi-Layer Perceptron dengan memetakan kontribusi fitur secara transparan. Visualisasi pada Gambar 8. menunjukkan bahwa model menempatkan indikator oksigenasi jaringan, yaitu rasio SpO_2/FiO_2 (SF_ratio) dan saturasi oksigen minimum enam jam terakhir (O2Sat_min6h), sebagai fitur paling berpengaruh di papan atas setelah suhu tubuh. Karakteristik sebaran titik pada O2Sat_min6h secara eksplisit memperlihatkan bahwa nilai fitur yang rendah (ditandai dengan warna biru) berkorelasi langsung dengan lonjakan nilai SHAP positif. Pola komputasi ini berjalan beriringan dengan realitas klinis hipoksia jaringan pada pasien sepsis, di mana penurunan saturasi oksigen mencerminkan kegagalan perfusi mikrosirkulasi sistemik dan hantaran oksigen ke sel perifer yang menjadi pemicu utama kondisi kritis pasien.

Kondisi hipoksia sistemik tersebut secara langsung mendisregulasi siklus metabolik pada tingkat seluler. Ketika pasokan oksigen menuju mitokondria terhambat, rantai transpor elektron di membran dalam mitokondria tidak dapat berjalan sehingga proses fosforilasi oksidatif

dan siklus Krebs terhenti sepenuhnya untuk memproduksi *adenosine triphosphate* (ATP) melalui respirasi aerobik. Untuk mempertahankan kelangsungan hidup sel di tengah krisis energi, metabolisme sel terpaksa bergeser ke jalur glikolisis anaerobik di dalam sitoplasma meskipun jalur kompensasi ini hanya menghasilkan energi yang sangat terbatas. Konsekuensi biokimia dari proses anaerobik ini terekam secara jelas pada grafik SHAP melalui fitur kadar laktat (Lactate) di posisi ke-13, di mana nilai laktat yang tinggi (warna merah) secara konsisten mendorong peningkatan probabilitas prediksi model ke arah sepsis. Akumulasi asam laktat yang tinggi ini menjadi bukti matematis sekaligus biologis terjadinya asidosis laktat akibat mekanisme pertahanan energi sel yang sedang berada dalam fase kritis.

Integrasi komprehensif antara penanda hipoksia jaringan (SF_ratio dan O2Sat_min6h) serta produk akhir krisis metabolik (Lactate) di dalam struktur penalaran model membuktikan signifikansi fungsi metabolisme sebagai pilar utama dalam sistem peringatan dini sepsis. *Neural network* tidak sekadar mengandalkan fluktuasi tanda vital makro, melainkan berhasil mengenali sidik jari klinis dari disfungsi mikrosirkulasi dan kegagalan metabolisme seluler sebelum bermanifestasi menjadi kegagalan multi organ total. Dengan demikian, visualisasi SHAP ini memberikan validasi ilmiah yang kokoh bahwa pemantauan dinamis terhadap pergeseran jalur energi seluler memiliki nilai prediktif yang sangat tinggi untuk mendeteksi progresi sepsis secara dini, objektif, dan akurat di unit perawatan intensif.

IV. KESIMPULAN

4.1 Kesimpulan

Penelitian ini berhasil mengembangkan sistem peringatan dini krisis metabolik dan hipoksia jaringan pada kondisi sepsis menggunakan arsitektur Multi-Layer Perceptron (MLP) dan Explainable AI (SHAP). Model terbukti mampu mengenali pola krisis klinis secara mandiri murni berdasarkan penanda biologis. Capaian utama penelitian disimpulkan dalam dua poin berikut:

1. Sistem memprioritaskan keselamatan jiwa pasien dengan mencapai nilai *recall* 0,750 pada tingkat pemantauan per jam maupun per pasien. Hal ini menegaskan keandalan model dalam meminimalkan kasus luput deteksi (*false negatives*) yang berpotensi fatal pada skenario darurat ICU, meskipun harus mengkompromikan laju alarm palsu akibat rendahnya *specificity* pada tugas skrining.
2. Analisis SHAP secara empiris membuktikan bahwa prediksi model sejalan dengan patofisiologi klinis, yang digerakkan oleh indikator hipoksia (O2Sat, rasio SpO_2/FiO_2) dan asidosis laktat (*Lactate*). Melalui interaksinya dengan parameter vital dan organ krusial lainnya (Temp, HR, BUN, Hgb, SBP), sistem ini tervalidasi sebagai instrumen yang transparan dan akurat dalam merefleksikan

kegagalan respirasi seluler sebelum terjadinya disfungsi multi-organ total.

4.2 Saran

Untuk mengatasi batasan teknis penelitian ini, terdapat tiga arah pengembangan yang direkomendasikan. Pertama, mengganti pendekatan temporal manual berbasis *rolling mean* enam jam dengan arsitektur *deep learning* sekuensial tingkat lanjut seperti LSTM, GRU, atau Transformer agar dependensi temporal jangka panjang antar pengukuran ICU dapat ditangkap secara dinamis dan otomatis. Kedua, menerapkan algoritma imputasi berbasis *machine learning* atau generatif seperti MICE, MissForest, atau GAIN berbasis GAN khusus untuk parameter laboratorium dengan sparsity tinggi, sehingga varians asli Lactate dan penanda metabolik lain dapat dipertahankan tanpa terjadinya *flattening* akibat *forward-fill*. Ketiga, melakukan validasi eksternal pada dataset klinis berskala internasional untuk menguji generalisasi dan ketangguhan model sebelum diimplementasikan pada lingkungan deployment ICU sesungguhnya.

V. DAFTAR PUSTAKA

- [1] Brealey, D., Brand, M., Hargreaves, I., et al. (2002). "Association between mitochondrial dysfunction and severity and outcome of septic shock". *The Lancet*, 360(9328), 219-223.
- [2] De Backer, D., Donadello, K., Sakr, Y., et al. (2013). "Microcirculatory alterations in patients with severe sepsis: impact of time of assessment and relationship with outcome". *Critical Care Medicine*, 41(3), 791-799.
- [3] Fleuren, L. M., Klausch, T. L. T., Zwager, C. L., et al. (2020). "Machine learning for the prediction of sepsis: a systematic review and meta-analysis of diagnostic test accuracy". *Intensive Care Medicine*, 46(3), 383-400.
- [4] Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.
- [5] Johnson, A. E. W., Pollard, T. J., Shen, L., et al. (2016). "MIMIC-III, a freely accessible critical care database". *Scientific Data*, 3, 160035.
- [6] Kingma, D. P., & Ba, J. (2014). "Adam: A method for stochastic optimization". *arXiv preprint arXiv:1412.6980*.
- [7] Kraut, J. A., & Madias, N. E. (2014). "Lactic acidosis". *New England Journal of Medicine*, 371(24), 2309-2319.
- [8] Lundberg, S. M., & Lee, S.-I. (2017). "A unified approach to interpreting model predictions". *Advances in Neural Information Processing Systems (NeurIPS)*, 30.
- [9] Nair, V., & Hinton, G. E. (2010). "Rectified linear units improve restricted boltzmann machines". *Proceedings of the 27th International Conference on Machine Learning (ICML-10)*.
- [10] Nelson, D. L., & Cox, M. M. (2017). *Lehninger Principles of Biochemistry* (7th ed.). W. H. Freeman.
- [11] Rumelhart, D. E., Hinton, G. E., & Williams, R. J. (1986). "Learning representations by back-propagating errors". *Nature*, 323(6088), 533-536.
- [12] Singer, M., Deutschman, C. S., Seymour, C. W., et al. (2016). "The Third International Consensus Definitions for Sepsis and Septic Shock (Sepsis-3)". *JAMA*, 315(8), 801-810.